Relatório Estatístico

Inclusão digital: conectividade e acesso à internet nos países

Global Solution – MLAM – Desafio CitizenTech

Integrantes: Conrado Gracie – RM569157 | Renato Sandreschi – RM569156

Documento elaborado com Python (pandas, NumPy, scikit-learn, matplotlib, seaborn). Código completo no notebook do repositório.

1. Contextualização do problema

Problema escolhido (CitizenTech – cidades e comunidades): a inclusão digital. Quais indicadores de infraestrutura de conectividade (telefonia celular e banda larga) estão mais associados à parcela da população que usa internet? Entender isso ajuda governos e empresas a decidir onde investir para reduzir a exclusão digital de comunidades.

Objetivo: medir o quanto a infraestrutura de banda larga e telefonia celular se relaciona com o uso de internet e produzir modelos simples de explicação, previsão e classificação que apoiem a decisão de onde investir em conectividade.

2. Descrição dos dados e procedimentos

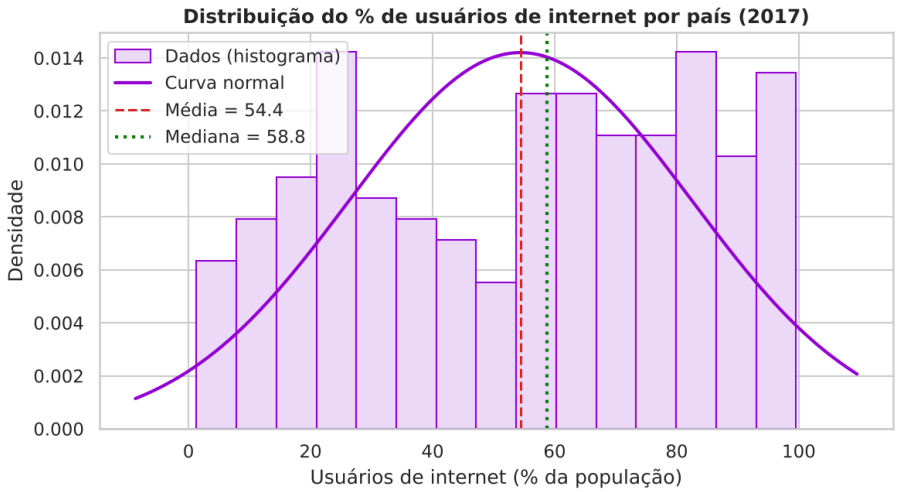
Base: Final.csv, com indicadores anuais por país (1980–2020): assinaturas de celular por 100 habitantes, usuários de internet (% da população), número de usuários de internet e assinaturas de banda larga por 100 habitantes. A base é real (não sintética); fonte e endereço de acesso constam no README.

Limpeza realizada (reproduzível no notebook):

- Remoção da coluna de índice e de linhas que não são países (regiões, grupos de renda e total mundial);
- Seleção do ano de 2017, para ter uma observação por país (observações independentes) e o ano recente com maior cobertura;
- Remoção de 11 países com valor 0 em alguma variável, pois nesta base o zero representa dado ausente (ex.: 0% de internautas é implausível);
- Base final: 193 países.

Variável	Média	Desvio padrão	Mínimo	Mediana	Máximo	Assimetria
Internet (% pop.)	54,40	28,16	1,31	58,77	99,55	-0,17
Celular (/100 hab.)	108,66	40,08	20,36	111,55	328,79	0,77
Banda larga (/100 hab.)	14,51	14,61	0,00	9,68	56,24	0,74

3. Distribuição Normal de Probabilidade



Evento	Probabilidade	Classificação
P(X menor que a média)	0,5000 (50,00%)	evento equiprovável (50%)
P(X maior que a mediana)	0,4381 (43,81%)	evento improvável (p < 0,5)

Interpretação: Usamos o percentual de usuários de internet de 193 países em 2017 (média 54,40%, mediana 58,77%, desvio padrão 28,09 p.p.). a) P(X menor que a média) = 0,5000 (50,00%): evento equiprovável (50%). Isso é esperado: na normal, a média é o ponto central, com metade da probabilidade de cada lado. b) P(X maior que a mediana) = 0,4381 (43,81%): evento improvável (p < 0,5). Como a mediana (58,77) é maior que a média (54,40), a probabilidade fica abaixo de 50%. Cuidado: a assimetria é pequena (-0,17), mas a curtose é -1,22, ou seja, a distribuição é bem mais achatada que uma normal, e a variável é limitada entre 0 e 100%. A suposição de normalidade pedida no enunciado é, portanto, uma aproximação.

4. Testes de hipóteses para a média

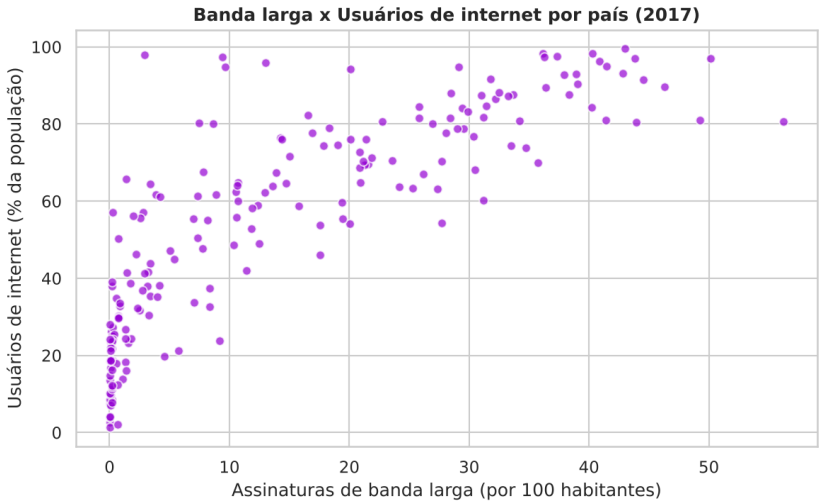
Teste Z com média de referência μ0 = 54,40 e desvio padrão de referência σ = 28,09 (valores da base).

Item	H0 / H1	n	Alfa	Média amostral	Z calc.	Z crít.	p-valor	Decisão
a)	μ = 54.40 / μ < 54.40	20	6%	58,64	0,675	-1,555	0,7503	Não rejeita H0
b)	μ = 54.40 / μ > 54.40	25	9%	57,06	0,473	1,341	0,3180	Não rejeita H0

Interpretação a): Com n = 20 e nível de significância de 6%, a média amostral foi 58,64, Z = 0,675, Z crítico = -1,555 e p-valor = 0,7503. Não se rejeita H0: não há evidência suficiente de que a média seja menor que a média de referência (54,40). A diferença observada pode ser apenas variação do sorteio da amostra.

Interpretação b): Com n = 25 e nível de significância de 9%, a média amostral foi 57,06, Z = 0,473, Z crítico = 1,341 e p-valor = 0,3180. Não se rejeita H0: não há evidência suficiente de que a média seja maior que a média de referência (54,40). A diferença observada pode ser apenas variação do sorteio da amostra.

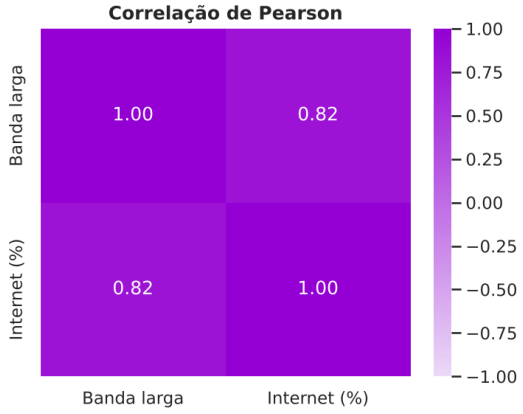
5. Análise bivariada: banda larga x internet



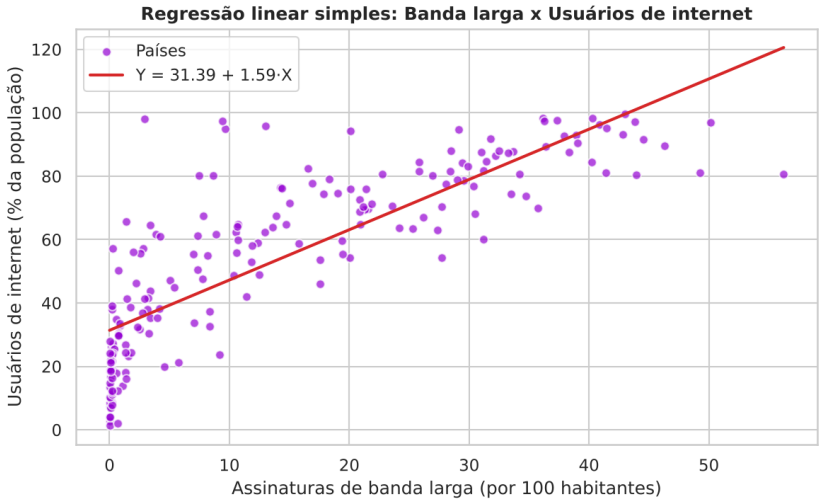
Dispersão: A nuvem de pontos sobe da esquerda para a direita: países com mais assinaturas de banda larga tendem a ter maior % de usuários de internet. A relação é crescente e não perfeitamente linear: o ganho é mais rápido nos países com pouca banda larga e tende a se achatar perto de 100%, pois o percentual não pode passar disso.

Medida	Valor
Covariância	338,71
Correlação de Pearson (r)	0,8230
R^2	0,6774
Estatística F (gl 1 e 191)	401,0
F crítico (5%)	3,88
p-valor do teste F	menor que 0,000001

Covariância e correlação: A covariância (338,71) é positiva: as variáveis variam no mesmo sentido. Mas a covariância depende da unidade de medida e não diz a intensidade. Por isso usamos a correlação de Pearson, r = 0,8230, que indica correlação linear forte e positiva.



O mapa de calor confirma r = 0,82 entre as duas variáveis (a diagonal vale 1, pois cada variável é perfeitamente correlacionada consigo mesma). Correlação não implica causalidade: banda larga e internet crescem juntas, mas outros fatores (renda, educação) podem influenciar ambas.

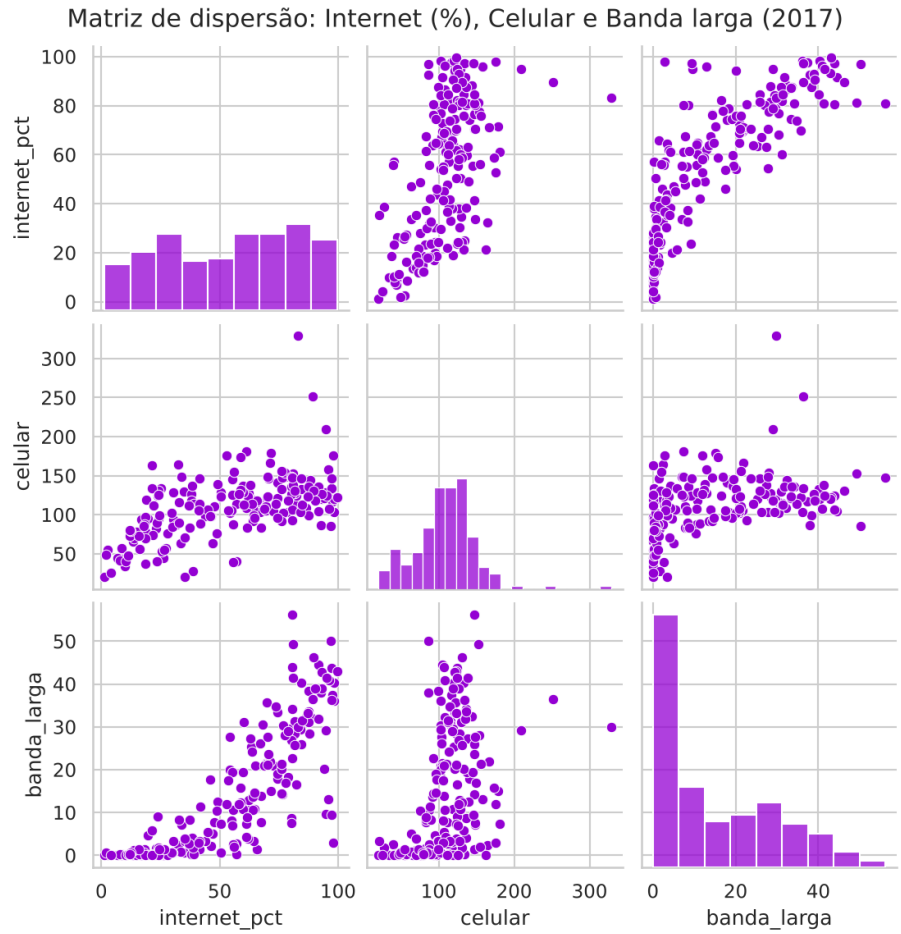


Equação: Internet(%) = 31,385 + 1,586 × Banda larga. O intercepto indica ~31,4% de usuários quando a banda larga é zero (valor teórico). O coeficiente indica que, em média, cada assinatura de banda larga a mais por 100 habitantes está associada a +1,59 ponto percentual de usuários de internet.

Adequação do modelo: R^2 = 0,6774: a banda larga explica cerca de 67,7% da variação do % de usuários de internet entre os países. Teste F: F calculado = 401,0 e F crítico (5%) = 3,88; como F calculado é maior que o crítico (p-valor menor que 0,000001), rejeita-se H0 e o modelo é estatisticamente significativo. Os 32,3% restantes dependem de outros fatores não incluídos. Atenção: a reta ultrapassa 100% para países com mais de ~43 assinaturas de banda larga, o que é impossível; isso mostra que a relação real é curva (cresce rápido no início e desacelera) e que o modelo linear só deve ser usado dentro do intervalo dos dados.

Previsão: Para um país com 20 assinaturas de banda larga por 100 habitantes, o modelo prevê ≈ 63,10% de usuários de internet. O valor 20 está dentro do intervalo observado (0,00 a 56,24), portanto é uma interpolação, não uma extrapolação.

6. Regressão linear múltipla



A matriz de dispersão mostra, na linha de Internet (%), relação crescente tanto com banda larga quanto com celular. Banda larga mostra tendência mais nítida; celular tem mais dispersão (países com muitos chips por habitante e % de internautas diferentes).

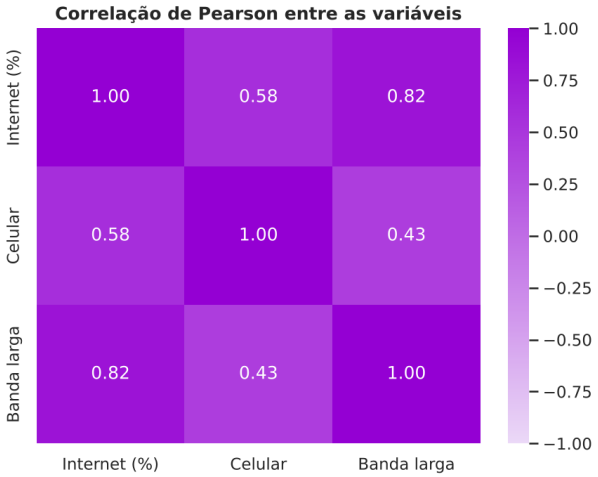
Matriz de covariância

	Internet (%)	Celular	Banda larga
Internet (%)	792,96	651,20	338,71
Celular	651,20	1.606,53	252,44
Banda larga	338,71	252,44	213,58

Matriz de correlação de Pearson

	Internet (%)	Celular	Banda larga
Internet (%)	1,000	0,577	0,823
Celular	0,577	1,000	0,431
Banda larga	0,823	0,431	1,000

Correlação com a internet: banda larga r = 0,823 (forte) e celular r = 0,577 (moderada). Entre as explicativas, celular e banda larga têm r = 0,431 (moderada), o que não indica multicolinearidade preocupante. As covariâncias na matriz têm o mesmo sinal positivo, mas dependem da escala de cada variável.



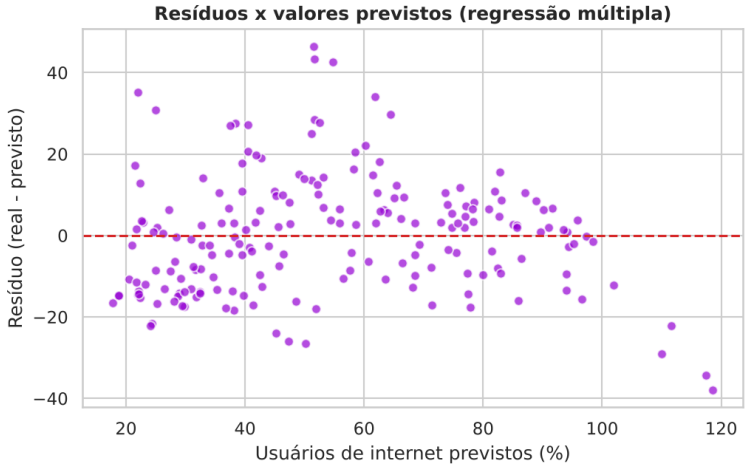
O mapa de calor destaca visualmente que a banda larga é a variável mais associada à internet, seguida pelo celular; as cores mais escuras indicam correlações mais fortes.

Equação e coeficientes

Equação: Internet(%) = 13,837 + 0,192 × Celular + 1,359 × Banda larga. Mantendo a banda larga fixa, +1 assinatura de celular por 100 hab. se associa a +0,192 p.p. de internautas; mantendo o celular fixo, +1 assinatura de banda larga se associa a +1,359 p.p. Banda larga tem o maior coeficiente, mas atenção: as duas variáveis estão em escalas diferentes, então os coeficientes não devem ser comparados diretamente.

Termo	Coeficiente
Intercepto	13,8368
Celular	0,1918
Banda larga	1,3592

Adequação do modelo: R^2 = 0,7380 e R^2 ajustado = 0,7353: o modelo com as duas variáveis explica cerca de 73,8% da variação, mais do que a regressão simples (67,7%). Teste F: F calculado = 267,7 e F crítico (5%) = 3,04; rejeita-se H0 (p-valor menor que 0,000001), o modelo é significativo. No gráfico de resíduos, os pontos ficam espalhados em torno de zero, mas há um leve formato de curva: resíduos majoritariamente positivos na faixa intermediária de valores previstos (≈ 40% a 65%) e negativos nas pontas, e os previstos acima de 100% (impossíveis) têm resíduos negativos grandes. Isso indica que a relação não é perfeitamente linear, o que é uma limitação do modelo.



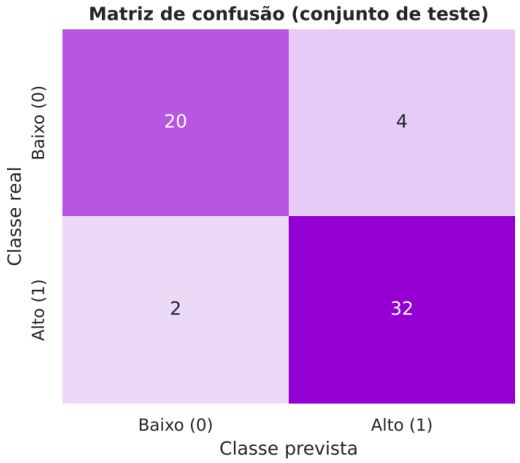
Previsão: Para um país com 110 assinaturas de celular e 15 de banda larga por 100 habitantes, o modelo prevê ≈ 55,32% de usuários de internet.

7. Regressão logística binária

Variável resposta: acesso alto = 1 se pelo menos 50% da população usa internet, 0 caso contrário. Explicativas: celular e banda larga. Divisão 70% treino / 30% teste (estratificada, semente 42).

Equação: $\ln(p/(1-p)) = -4{,}0916 + 0{,}0194 \times \text{Celular} + 0{,}3010 \times \text{Banda larga}$, em que p é a probabilidade de o país ter acesso alto (≥ 50% usando internet). Razões de chance: cada assinatura de celular a mais multiplica a chance por 1,020; cada assinatura de banda larga a mais, por 1,351. Valores acima de 1 indicam que a variável aumenta a chance de acesso alto.

	Previsto: baixo (0)	Previsto: alto (1)
Real: baixo (0)	20	4
Real: alto (1)	2	32



No conjunto de teste (58 países) o modelo acertou 52 e errou 6. Verdadeiros negativos = 20, falsos positivos = 4, falsos negativos = 2, verdadeiros positivos = 32. Acurácia = 89,7% (treino: 89,6%). Como referência, sempre prever a classe mais comum daria 58,6%; portanto o modelo supera claramente esse chute. Treino e teste com acurácias próximas indicam que não houve sobreajuste importante. O conjunto de teste é pequeno, então a acurácia tem incerteza.

Classificação: País A (celular 120, banda larga 10): probabilidade de acesso alto = 77,6% → Acesso alto (1). País B (celular 60, banda larga 1): probabilidade = 6,7% → Acesso baixo (0). A regra usada é: p ≥ 0,5 classifica como acesso alto.

Comparação com outros classificadores

Modelo	Acurácia	Precisão	Recall	F1
Regressão logística	0,897	0,889	0,941	0,914
KNN (k = 5)	0,931	0,917	0,971	0,943
Árvore de decisão (profundidade 3)	0,914	0,892	0,971	0,930

Comparamos a regressão logística com dois algoritmos de classificação (KNN com k = 5, usando variáveis padronizadas, e árvore de decisão com profundidade 3) na mesma divisão treino/teste. Acurácias no teste: logística 89,7%, KNN 93,1% e árvore 91,4%. A maior acurácia foi de: KNN (k = 5). Com apenas 58 países no teste, uma diferença de 1 ou 2 acertos não é conclusiva; o importante é que os três modelos têm desempenho parecido e muito acima do chute (58,6%). A regressão logística tem a vantagem de fornecer uma equação interpretável (razões de chance), enquanto KNN e árvore costumam ser mais flexíveis, porém menos explicativos.

8. Insights para a tomada de decisão

• A banda larga é a variável mais fortemente associada ao acesso à internet (r = 0,82); sozinha explica ≈ 68% da variação entre países.

• Somando celular e banda larga o poder explicativo sobe para ≈ 74%, mostrando que as duas infraestruturas se complementam.

• Para o CitizenTech, priorizar banda larga fixa em comunidades pouco conectadas tende a trazer mais ganho de inclusão do que apenas ampliar o número de linhas de celular.

• O modelo logístico classifica corretamente ≈ 90% dos países como de acesso alto ou baixo; KNN e árvore de decisão chegam a resultados parecidos, o que reforça a robustez da conclusão.

9. Limitações

• Os dados são por país (nível agregado) e de um único ano (2017). Não descrevem cidades, zonas rurais ou comunidades específicas; conclusões sobre o território interno de um país exigiriam dados locais.

• Foram excluídos 11 países que tinham valor 0 (dado ausente) em alguma variável, o que pode enviesar a amostra para países que reportam melhor seus dados.

• Associação não é causalidade: renda, educação, urbanização e preço dos planos não estão no modelo e podem influenciar todas as variáveis.

• A normalidade foi assumida conforme o enunciado, mas o percentual de internautas é limitado entre 0 e 100% e a distribuição é achatada; a aproximação é imperfeita.

• Os testes de hipóteses usam uma amostra aleatória (semente 42); outra amostra poderia levar a conclusões diferentes, o que é natural em testes com n pequeno.

• O p-valor do teste F é obtido por simulação (1.000.000 de sorteios); quando nenhuma simulação alcança o F calculado, informa-se apenas que o p-valor é menor que 0,000001.

• Celular pode passar de 100 por 100 habitantes porque uma pessoa pode ter mais de um chip, o que dificulta a interpretação direta.

• O limiar de 50% na regressão logística é uma escolha do grupo; outro limiar alteraria a matriz de confusão.

10. Conclusão

Os dados mostram que conectividade de banda larga e telefonia celular estão fortemente associadas ao uso de internet nos países: o modelo múltiplo explica ≈ 74% da variação e o modelo logístico classifica ≈ 90% dos países corretamente. Para o desafio CitizenTech, isso aponta a banda larga como foco prioritário de ações de inclusão digital, sempre combinada com análises locais (renda, educação, urbanização) antes de decidir investimentos, já que os resultados descrevem associações entre países e não relações causais em comunidades específicas.